Cel projektu

Celem projektu było stworzenie kompilatora do prostego języka z wykorzystaniem parsera rekursywnego zstępującego i LLVM w celu kompilacji do formy pośredniej IR lub kompilacji JIT.

Ostateczna specyfikacja gramatyki

```
Program = VariableDeclStatement | FunctionDecl | ExternFuncDecl, { FunctionDecl
| VariableDeclStatement | ExternFuncDecl }
FunctionDecl = "fn", Identifier, "(", DeclArgumentList, ")", "->", VarType,
ExternFuncDecl = "extern" "fn", Identifier, "(", DeclArgumentList, ")", "-
>", VarType, ";";
DeclArgumentList = [ Identifier, ":", VarType, { ",", Identifier, ":", VarType }
VarType = "int" | "string" | VarType, "*";
ConditionalExpression= UnaryLogicalExpr, { ("&&" | "||"), UnaryLogicalExpr} ;
UnaryLogicalExpr = ["!"], LogicalExpr;
LogicalExpr = ArithmeticalExpr, { ( "<" | ">" | "<=" | ">=" | "==" | "!="),
ArithmeticalExpr } ;
ArithmeticalExpr = AdditiveExpr, { ( "&" | "|" | "^{"} | "<" |">>"), AdditiveExpr}
AdditiveExpr = MultiplicativeExpr, \{ ("+", "-"), MultiplicativeExpr \} ;
MultiplicativeExpr = UnaryExpression, { ( "*", "/", "%"), UnaryExpression } ;
UnaryExpression = { "*", "&", "~", "-"} , Factor, [ "[", ArithmeticalExpr, "]" ]
Factor = Identifier | IntegerConst | StringConst | FunctionCall | "(",
ConditionalExpression, ")";
FunctionCall = Identyfier, "(", CallArgumentList, ")";
CallArgumentList = [ ArithmeticalExpr, { "," , ArithmeticalExpr} ] ;
Statement =
        IfStatement |
        ForStatement |
        WhileStatement |
        ReturnSatetemnt |
        VariableDeclStatement |
```

```
AssignStatement |
        ConditionalExpression, ";"
    );
AssignStatement = ConditionalExpression, { "=", ConditionalExpression }, "=",
ArithmeticalExpr ;
Block = "{", { Statement }, "}" ';
IfStatement = "if", ConditionalExpression, Block, { "elif",
ConditionalExpression, Block } , ["else", Block ];
ForStatement = "for", Identifier, "in", ArithmeticalExpr, "..",
ArithmeticalExpr, ["..", ArithmeticalExpr],
WhileStatement = "while", ConditionalExpression, Block;
ReturnStatement = "return", ArithmeticalExpr;
VariableDeclStatement = "let", Identifier, [ "=", ArithmeticalExpr], { ",",
Identifier, [ "=",
ArithmeticalExpr] } , ":", VarType, ";" ;
Letter = "a" | "b" | "c" | "d" | ... | "X" | "Y" | "Z" ;
FirstDigit = "1" | "2" | "3" | "4" | "5" | "6" | "7" | "8" | "9" ;
Digit = "0" | "1" | "2" | "3" | "4" | "5" | "6" | "7" | "8" | "9" ;
SpecialChar = "`" | "~" | "!" | "@" |"#" | "$" | "%" | "\" | "&" | "*" | "(" |
")" | "-" | "=" | "+" | "[" | "]"
| '\"' | ";" | ":" | ":" | "<" | ">" | "," | ":" | "?" | "/" | "|" | "{" | "}" ;
IntegerConst = ["-"], Firstdigit, { Digit } ;
StringConst = '"', { Letter | Digit | SpecialChar }, '"';
Idetifier = Letter, { Letter | Digit } ;
```

W porównaniu do gramatyki z dokumentacji wstępnej dodana została produkcja definiująca deklaracje nagłówka funkcji w celu umożliwienia korzystania z funkcji z bibliotek dynamicznych np malloc, free itd. Uproszczona została również reguła operatora przypisania, zamiast wyrażenia MutableExpression zostały podstawione ConditionalExpression aby maksymalnie uogólnić gramatyka. Ze względu na ogólność reguł, ich poprawność jest sprawdzana na późniejszym etapie analizy semantycznej.

W języku dostepne są następujące typy:

typ	rozmiar	opis
int	4 bajty	liczba U2 od -2^32 do 2^32 - 1
int*	4/8 bajtów zależy od architektury	wskaźnik na typ int
string	-	stały napis odpowiednik const wchar_t*

Przykłady kodu

```
extern fn putwchar(chr : int) -> int;

fn putstr(str: string) -> int {
    let i=0 : int;
    while str[i] {
        putwchar(str[i]);
        i = i + 1;
    }
}
```

```
}
  return i;
}

fn main() -> int {
   putstr("OKI");
   return 0;
}
```

```
extern fn putwchar(chr : int) -> int;
fn putint(num : int) -> int {
   if num == 0 {
       return 0;
   }
   let digit = num % 10 : int;
    putint(num / 10);
    putwchar(digit + 48);
   return 0;
}
fn putstr(str: string) -> int {
   let i=0 : int;
   while str[i] {
       putwchar(str[i]);
       i = i + 1;
   }
   return i;
}
fn main() -> int {
   for i in 1..20 {
        putint(i);
       putstr("\n");
    return 0;
}1
```

```
extern fn putwchar(chr : int) -> int;

fn putstr(str: string) -> int {
    let i=0 : int;
    while str[i] {
        putwchar(str[i]);
        i = i + 1;
    }
    return 0;
}

fn is_prime(num : int) -> int {
    for i in 2..(num / 2 + 1) { # chciałem zrobić sqrt ale nie mam floatów
        if num % i == 0 {
            return 0;
        }
    }
    return 1;
```

```
fn main() -> int {
    let num=2 : int;
    while num < 10 {
        if is_prime(num) {
            putwchar(num+48);
        } else {
            putstr("-");
        }
        num = num + 1;
    }
    return 0;
}</pre>
```

Oraz większy przykład interpreter języka brainfuck

```
extern fn putwchar(chr : int) -> int;
extern fn malloc(size : int) -> int*;
extern fn getchar() -> int;
extern fn free(ptr : int*) -> int;
extern fn memset(ptr : int*, val : int, size : int) -> int*;
let code : int*;
let ram : int*;
let ptr = 0 : int;
let ip = 0: int;
fn putstr(str: string) -> int {
   let i=0 : int;
   while str[i] {
        putwchar(str[i]);
        i = i + 1;
   }
   return 0;
}
fn readstr(ptr : int*, size : int) -> int* {
   for i in 0..size {
        let ch=getchar() : int;
        if ch == 10 {
           return ptr;
        ptr[i] = ch;
    return ptr;
}
fn read_char() -> int {
    ram[ptr] = getchar();
    return 0;
}
fn print_char() -> int {
    putwchar(ram[ptr]);
    return 0;
```

```
}
fn inc() -> int {
    ram[ptr] = ram[ptr] + 1;
    return 0;
}
fn dec() -> int {
    ram[ptr] = ram[ptr] - 1;
    return 0;
}
fn next() -> int {
   ptr = ptr + 1;
    return 0;
}
fn prev() -> int {
   ptr = ptr - 1;
    return 0;
}
fn go_to_loop_beg() -> int {
   ip = ip - 1;
    let count = 1 : int;
    while count > 0 {
        if code[ip] == 91 {
            count = count - 1;
        } elif code[ip] == 93 {
            count = count + 1;
        }
        ip = ip - 1;
    }
   return 0;
}
fn go_to_loop_end() -> int {
   if ram[ptr] == 0 {
        ip = ip + 1;
        let count = 1 : int;
        while count > 0 {
            if code[ip] == 91 { # '['
                count = count + 1;
            } elif code[ip] == 93 { # ']'
                count = count - 1;
            }
            ip = ip + 1;
        ip = ip - 1;
    return 0;
}
fn debug(opcode : int) -> int {
    putstr("ip "); putint(ip); putstr("\n");
    putstr("ptr "); putint(ptr); putstr("\n");
    putstr("opcode "); putwchar(opcode); putstr("\n");
    return 0;
```

```
}
fn execute() -> int {
    while code[ip] {
        let opcode = code[ip] : int;
        #debug(opcode);
        if opcode == 44 { # ','
            read_char();
        } elif opcode == 46 { # '.'
            print_char();
        } elif opcode == 43 { # '+'
            inc();
        } elif opcode == 45 { # '-'
            dec();
        } elif opcode == 62 { # '>'
            next();
        } elif opcode == 60 { # '<'
            prev();
        } elif opcode == 91 { # '['
            go_to_loop_end();
        } elif opcode == 93 { # ']'
            go_to_loop_beg();
        } else {
            putstr("Invalid opcode ");
            putwchar(opcode);
            return -1;
        }
        ip = ip + 1;
    }
    return 0;
}
fn main() -> int {
    putstr("Podaj program brainfucka: ");
    let size = 32768 : int;
    ram = malloc(size);
    code = malloc(size);
    memset(ram, 0, size);
    memset(code, 0, size);
    readstr(code, size);
    execute();
    free(ram);
    free(code);
    return 0;
}
```

Zaimplementowałem też w moim kompilatorze obsługe znaków UTF-8 dzięki czemu można używać tych znaków jako nazw funkcji / zmiennych (poza funkcją "main", ta nazwa musi pozostać).

```
extern fn putwchar(chr : int) -> int;

fn putstr(str: string) -> int {
   let l = 0 : int;
   while str[l] {
      putwchar(str[l]);
   }
}
```

Użycie

Program umożliwia:

1. Kompilacje JIT

2. Kompilacje z wypisaniem pseudoassemblera LLVM

```
loczek@loczek-pc ~ $ ./rc --input-file=brainfuck.r --print-ir
; ModuleID = 'top'
source_filename = "top"
target datalayout = "e-p:64:64:64-i1:8:8-i8:8-i16:16:16-i32:32:32-i64:64:64-
f32:32:32-f64:64:64-v64:64:64-v128:128:128-a0:0:64-s0:64:64-f80:128:128"
target triple = "x86_64-unknown-linux-gnu"
@0 = common global i32* null
@1 = common global i32* null
@2 = common global i32 0
@3 = common global i32 0
\00\00\00\00\00\00\00\00", align 1
align 1
\00\00\00\00\00\00\00\00", align 1
align 1
```

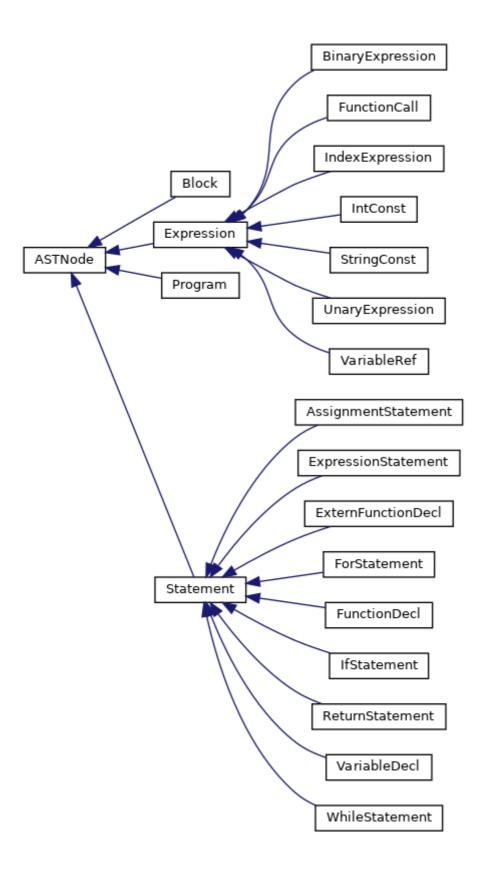
3. Kompilacje z zapisaniem pseudoassemblera do pliku (można go potem uruchomić narzędziem lli lub skompilować do postaci binarnej clangiem)

4. Kompilacje do bytecode'u LLVM

Parsing:

Po leksykalizacji następuje parsowanie do drzewka składającego się z różnych struktur opisujących konstrukcje językowe. Każda reguła gramatyczna odzwierciedlająca kolejne poziomy priorytetów operatorów przekładają się bezpośrednio na funkcje w parserze. Każda z tych funkcji jest zbudowana podobnie, narpiew następuje wywołanie funkcji od poziomu wyżej w hierarchii a następnie próba pobrania z lexera operatora. W przypadku leksemu nie zgodnego następuje zwrócenie wartości z funkcji wyższego poziomu, a w przeciwnym przypadku tworzone jest węzeł AST oraz ponowne zawołanie funkcji wyższego poziomu. Całość jest powtarzana do dopóty napotykany leksem jest przewidywanym operatorem.

Diagram klas



W celu lepszej prezentacji zamieściłem wynik uzyskany z PrintVisitora, który wiernie odwzorowuje zawartość węzłów w drzewie AST.

1. Stałe:

- liczba 0 zostanie zapisana jako [int `0`]
- napis "OKI" zostanie zapisany jako [string `OKI`]

2. Wyrażenia są zapisywane jako

```
pus : {
    Plus : {
        [ int `2` ]
        [ int `3` ]
      }
      [ int `4` ]
}
```

3. Referencja do zmiennej

```
[ get var `n` ]
```

4. Pętla for

<operator> : {
 agrumenty

```
for i in 0..n {
}
```

5. Petla while

```
while 1 {
}
```

6. Funkcja

```
fn t(n : int ) -> int {
    for i in 0..n {

    }
    return 0;
}
```

```
[ make function name = `t`; return type = `Int`; args = {
           name = `n`; type = `Int`,
      }
     with body = {
                [ for loop variable name = `i`
                     start = {
                          [ int `0` ]
                     },
                     end = {
                          [ get var `n` ]
                     },
                     increase = default;
                     with body = {
                     },
                 end for ],
                Return : {
                     [ int `0` ]
                },
     }
```

Analiza semantyczna

Do analizy semantycznej wykorzystuje wizytator Analyser.

Ze względu na ograniczoną ilość typów do int, int* i string, analiza poprawności wyrażeń uprasza się do sprawdzenia typu wyrażenia z wymaganym typem dla danego operatora:

```
case BinaryOperator::Plus:
case BinaryOperator::Minus:
case BinaryOperator::Multiply:
case BinaryOperator::Divide:
case BinaryOperator::Modulo:
case BinaryOperator::And:
case BinaryOperator::Xor:
case BinaryOperator::Or:
case BinaryOperator::ShiftLeft:
case BinaryOperator::ShiftRight:
    require(SemanticAnalyser::ExprType::Int,
SemanticAnalyser::ExprType::IntReference);
    require(SemanticAnalyser::ExprType::Int,
SemanticAnalyser::ExprType::IntReference);
    yield(SemanticAnalyser::ExprType::Int, pos);
    break;
```

W przypadku większej ilości typów wymagana byłaby tablica operatorów, gdzie każdy element zawierałby informacje o wymaganych typach wraz z mechanizmem niejawnej zmiany typów (tego mechanizmu też nie am w moim języku).

Analizie podlega również wartość zwracana funkcji na podstawie typu wpisanego w deklaracji oraz czy wszystkie ścieżki kończą się instrukcją "return".

Zmienne i scoping

W celu zapewnienia poprawnego działania Shadowingu i rejestracji zmienncyh w analizatorze zdefiniowany jest scope zmiennych jako :

```
std::deque<std::unordered_map<std::wstring, BuiltinType>> scopes
```

w momęcie wejścia w blok na koniec dodawana jest na koniec nowa mapa, a przy wyjściu ostatnia jest usuwana. Szukanie zmiennych następuje od końca. Przyjąłem konwencje że pierwszy scope jest scopem zmiennych globalnych a ostatni jest lokalnym obecnego bloku.

Interfejs do LLVM

Korzystanie z LLVM wymaga stworzenia globalnego obiektu klasy Ilvm::LLVMContext, który służy do zarządzania pamięcią dla dynamicznie alokowanych struktur Ilvm'a takich jak typy, zmienne globalne czy funkcje. Po stworzeniu i inicjalizacji Contextu następnym krokiem jest stworzenie obiektu klasy Ilvm::Module, który reprezentuje naszą jednostkę kompilacji. Module jest kontenerem w, którym będziemy tworzyć funkcje i bloki assemblereowe. Ostatnią potrzebną do kompilacji rzeczą jest Ilvm::IrBuilder, jest to bardzo przydatny obiekt wykorzystujący wzorzec fabryki do generowania instrukcji. Upraszcza to bardzo translacje drzewa AST do assemblera Ilvm.

W kompilatorze wykorzystuje bardzo podobny scoping do tego w analizatorze semantycznym, tylko oprócz nazw zmiennych przechowuje również wskaźnik na adres zwrócony przez instrukcje aloca służącą do alokacji zmiennych automatycznych na stosie lub w przypadku zmiennych globalnych wskaźnik na llvm::GlobalVariable.

Same zmienne mają typy takie same jak w parserze, jednakże aby rozróżnić sytuacje np przypisania typu a = b; musiałem dla wyrażeń wprowadzić dodatkowo typ referencji. Np jeżeli zmienna a ma typ int to wyrażenia a; jest typu IntReference. Natomiast wyrażenie a+1; jest już typu Int.

Dodanie referencji wprowadza dodatkową komplikacji przy wyliczaniu wyrażeń, np w przypadku patologicznym ale poprawnym gramatycznie:

```
*&*a = 1;
```

gdzie zmienna a jest typu IntPointer, po wykonaniu pierwszego operatora uzyskujemy typ IntReference, po pobraniu adresu typ IntPointer a potem z powrotem IntReference. Z tego powodu przy wyliczaniu każdego wyrażenia na stos emulujący rekursje w kompilatorze zawsze wstawiam pare (wartość, adres). W przypadku referencji adres jest nie zerowym wskaźnikiem na strukturę Ilvm::Value będącą efektem wykonania instrukcji aloca. W przypadku wartości nie będących referencjami pole adres ma wartość nullptr. W tym rozwiązaniu operacja pobrania adresu upraszcza się do pobrania z stosu pary (wartość, adres) i wstawienia (adres, nullptr). Operacja dereferencji wymaga pobrania pary (waretość, adres), stworzenia instrukcji load i wstawienia pary (wskaźnik na instrukcje load, wartość). Wybrałem to rozwiązanie ze względu na

stworzony analizator semantyczny, który upewnia się że nigdy nie zajdzie sytuacja w której nastąpi dereferencja nullptr będącego adresem (byłaby to sytuacja w której próbowalibyśmy wykonać operator * na zmiennej typu Int, taki kod nie przejdzie analizy semantycznej).

W celach optymalizacyjnych przy kompilacji operacji pobierających wartość z zmiennej wykorzystuje własną klasę lazyvalue, która wygeneruje instrukcje load tylko w przypadku, gdy jej wartość będzie wymagana. Pomaga to w czytaniu i debugowaniu, gdy wykonujemy tylko operacje na adresach i nie pobieramy wartości wskaźników. Oczywiście po włączeniu optymalizacji z llvm pod koniec kompilacji AST, nie ma to znaczenia gdyż te instrukcje i tak zostaną usunięte.

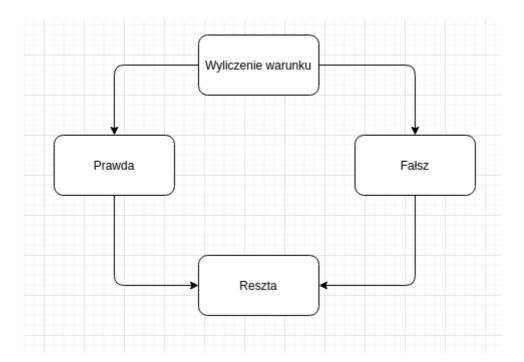
W kompilacji funkcji jedyną trudność jaką napotkałem było kopiowanie i inicjalizacja argumentów aby umożliwić korzystanie z argumentów jak z zmiennych lokalnych, gdyż tworzenie funkcji nie jest skomplikowane i ogranicza się do stworzenia Ilvm::BasicBlock, będącego "entry point", czyli blokiem wejściowym dla funkcji oraz zdefiniowania liczby i typów argumentów. W moim przypadku pierwszym blokiem jest zawsze blok alokujący argumenty oraz przypisującym im wartość. Jest to spowodowane faktem iż w Ilvmie wszystkie wartości są "read-only" i żeby stworzyć zmienną trzeba ją zaalokować na stosie i korzystać z instrukcji load, store do pobierania i ustawiania wartości.

W celu kompilacji kolejnych instrukcji, wykorzystując IRBuilder wystarczy na początku wskazać gdzie będziemy wstawiać instrukcje. Korzystając z funkcji SetInsertPoint, a następnie korzystając z metod fabryki (CreateStore, CreateLoad itd) dodawać kolejne instrukcje przeglądając w głąb drzewo AST. Niestety nie można robić tego w całkowicie automatyczny sposób. LLVM wymaga aby każdy blok kończył się instrukcją terminującą czyli albo skokiem albo powrotem i w każdym bloku może występować tylko 1 instrukcja terminująca. W przeciwnym przypadku przy próbie kompilacji JIT tak powstałego modułu LLVM zaprotestuje rzucając wyjątek. Aby temu zapobiec wprowadziłem mechanizm, który przegląda skompilowane bloki kodu i po wykryciu instrukcji terminującej blok usuwa wszystkie instrukcje występujące za nią.

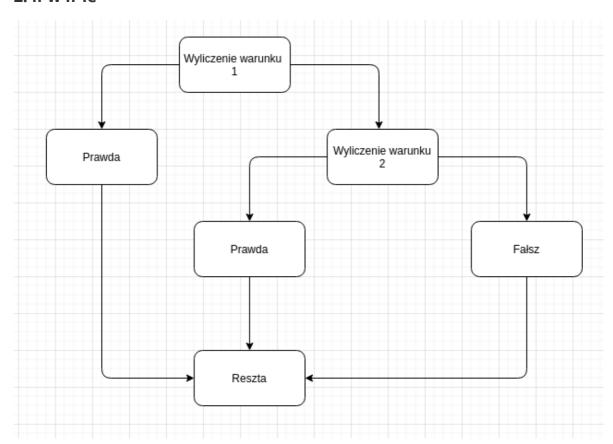
W celu obsługi zmiennych globalnych po kompilacji wszystkich funkcji generowana jest funkcja main, która pełni fukcjie __libc_start_main. W wygenerowanej funkcji następuje inicjalizacja zmiennych globalnych oraz po inicjalizacji wywołanie funkcji main z kodu źródłowego.

Odwzorowanie konstrukcji językowych w blokach assemblera:

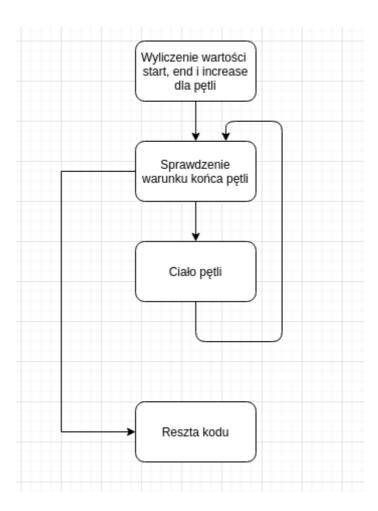
1. if



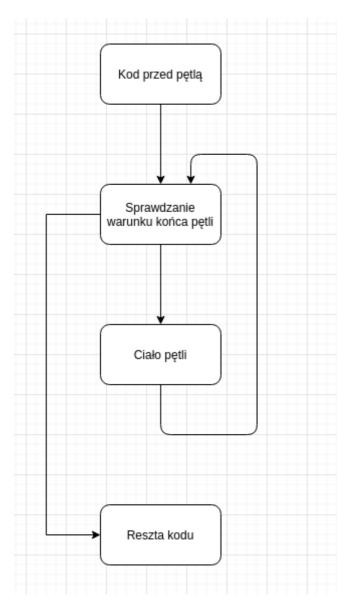
2. if w if'ie



3. Pętla for



4. Pętla while



Po skompilowaniu drzewa AST otrzymujemy moduł llvm'a który jest poddawany optymalizacji. Na początku usunięciu martwych instrukcji, okazuje się że llvm bardzo nielubi jak w danym bloku są np 2 instrukcje ret lub br. Następnie uruchamiam typowe przejścia optymalizacyjne z slajdu z wykładu.

```
auto FPM = std::make_unique<llvm::legacy::FunctionPassManager>
(module.get());
   FPM->add(llvm::createInstructionCombiningPass());
   FPM->add(llvm::createReassociatePass());
   FPM->add(llvm::createGVNPass());
   FPM->add(llvm::createCFGSimplificationPass());
   FPM->doInitialization();

for (auto & function : functions) {
     FPM->run(*function.second.llvm_ptr);
}
```

W przypadku wypisania assemblera wykonywane jest

```
void LLVMCompiler::print_ir() {
   module->print(llvm::outs(), nullptr);
}
```

Zapisanie do pliku:

```
void LLVMCompiler::save_ir(const std::string& path) {
   std::error_code ec;
   llvm::raw_fd_ostream fd(path, ec, llvm::sys::fs::F_None);
   fd << *module;
}

void LLVMCompiler::save_bc(const std::string& path) {
   std::error_code ec;
   llvm::raw_fd_ostream fd(path, ec, llvm::sys::fs::F_None);
   llvm::WriteBitcodeToFile(*module, fd);
}</pre>
```

I na końcu kompilacja JIT, dzięki LLVM wystraczy skorzystać z llvm::ExecutionEngine, znaleźć funkcje main i ją wykonać: